



MINISTÈRE
DE L'ENSEIGNEMENT
SUPÉRIEUR
ET DE LA RECHERCHE



UNIVERSITÉ
PARIS-EST CRÉTEIL
VAL DE MARNE

UNIVERSITÉ PARIS-EST CRÉTEIL
DÉPARTEMENT DE SCIENCES ÉCONOMIQUES

Master :

MÉTHODES APPLIQUÉES DE LA STATISTIQUE ET DE L'ÉCONOMETRIE POUR LA RECHERCHE,
L'ANALYSE ET LE TRAITEMENT DE L'INFORMATION

Module :

MEMOIRE

APPROCHE PROBABILISTE DE LA PRÉVISION LA CONSOMMATION D'ÉNERGIE A L'AIDE D'UN RESEAU BAYESIEN DYNAMIQUE

Présenté et soutenu par :

LAJOIE BENGONE AKOU

Sous la supervision de :

SYLVAIN CHAREYRON

ENSEIGNANT CHERCHEUR

Année universitaire :

2024-2025

TABLE DES MATIERES

TABLE DES MATIERES	2
1 INTRODUCTION	3
2 REVUE DE LITTERATURE	4
2.1 MODELES CONVENTIONNELS DE REGRESSION ET DE SERIE TEMPORELLE	4
2.2 MODELES D'APPRENTISSAGE AUTOMATIQUE.....	5
2.3 MODELES D'APPRENTISSAGE PROFOND	5
2.4 MODELES HYBRIDES	6
3 TABLEAU DE SYNTHESE	7
4 ETUDE EMPIRIQUE	11
4.1 DONNEES.....	11
4.2 STATISTIQUE DESCRIPTIVES	12
5 BIBLIOGRAPHIQUE.....	13

1 Introduction

L'évolution de l'humanité a été permise par une succession de découvertes. Parmi elles, figure la maîtrise des énergies. Ces énergies qui se manifestent sous différentes formes ont contribué de façon significative à l'amélioration des conditions de vie des individus et au dynamisme des sociétés modernes.

En effet, de la gestion du patrimoine routier à l'interopérabilité du système bancaire en passant par la maintenance des réseaux de télécommunication, le fonctionnement des infrastructures modernes est assuré en grande partie par l'intervention d'énergies.

Cependant, la disponibilité de ces énergies tend de plus en plus à diminuer menaçant ainsi les modes de production et de consommation actuels. Les causes apparentes derrière ce phénomène sont essentiellement d'ordre démographique et climatique. Parmi elles, on retrouve la croissance de la population mondiale et la raréfaction des ressources naturelles qui créent des tensions sur le marché de l'énergie en matière d'approvisionnement, de distribution et de consommation. Ces tensions, si elles ne sont pas maîtrisées peuvent donner lieu à des pertes financières auprès des consommateurs et des gestionnaires d'énergie.

Cela a été le cas pour les consommateurs européens, qui en 2022 ont été affectés par l'augmentation des coûts d'électricité. Il en résulte une baisse du pouvoir d'achat pour les ménages et une perte de la compétitivité pour les industriels (IEA, Electricity 2024).

Ainsi, face à cette crise énergétique, plusieurs travaux ont été menés avec comme objectif d'utiliser de façon plus efficiente l'énergie disponible. Parmi eux, on retrouve le développement des modèles de prévision de la consommation d'énergie à partir des méthodes de « data-driven ». Ces modèles de prévision, bénéficient aujourd'hui d'une grande attention de la part de la communauté scientifique qui voit en eux un moyen d'estimer la demande future d'énergie. Cette demande anticipée si elle est correcte et parfaitement ajustée à l'offre d'énergie, permettra de réaliser des économies et de préserver l'environnement.

C'est donc en vue de ces objectifs que le présent ouvrage se concentre sur le développement de l'une de ces méthodes. Il s'agira, ainsi, d'élaborer un modèle de prévision de la consommation d'énergie en se basant sur une récente approche appelée réseaux bayésien en utilisant des données collectées à l'aide des capteurs intelligents « smart meters ».

Pour se faire, les travaux ont été structurés comme suit. Dans un premier temps, il sera question d'effectuer une synthèse bibliographique de l'ensemble des méthodes d'analyse de données employées dans le cadre de la prévision de la consommation d'énergie. On retrouvera ainsi les objectifs des études, les méthodologies employées et les résultats des modèles. La deuxième partie s'articulera autour de la présentation de la base de données et la méthodologie retenue dans le cadre de la construction du modèle de prévision. Enfin, la dernière partie consistera au déploiement de l'algorithme de prévision. Cette partie sera constituée d'analyses exploratoires, des performances du modèle probabiliste ainsi que d'éventuels commentaires.

2 Revue de littérature

La prévision de la consommation d'énergie est un sujet complexe qui revêt entre autres des enjeux économiques et climatiques. Cette thématique suscite énormément l'intérêt de la communauté scientifique qui ne cesse de proposer des modèles de plus en plus sophistiqués dans le but d'atteindre l'optimalité en matière d'efficacité énergétique. Cette synthèse bibliographique présente un résumé non exhaustif des principales méthodes d'analyse de données employées.

2.1 Modèles conventionnels de régression et de série temporelle

Les modèles conventionnels regroupent les modèles de régression linéaire, non linéaire et de séries de temporelles. Ces modèles font partie des modèles d'analyse de données les plus anciens en matière de prévision de consommation d'énergie. Ils ont notamment été utilisés pour prédire les consommations d'énergies au niveau national, sectoriel et résidentiel.

Pour commencer, les modèles de régression ont été utilisés par exemple pour prédire la consommation d'électricité en Arabie Saoudite. En effet, en 1994 (Al-Garni et al, 1994) ont modélisé la consommation d'électricité mensuelle à partir d'une régression linéaire multiple. Les données qui ont été collectées entre 1987 et 1992 comprenaient les variables relatives à la température ambiante (T), à la taille de la population (P), à l'humidité (H) et aux radiations solaires (S).

$$E_p = 0.792015 P - 0.251461 H + 0.044328 T \times S + 0.433848 T \times H$$

Par ailleurs, (Tunc et al, 2006) ont prédit la consommation nette d'électricité en Turquie en utilisant la taille de la population et le taux de consommation par individu en tant que variables indépendantes.

Ensuite, d'autres études basées sur le développement des modèles de régression non linéaire ont été menées. A l'instar des travaux de (Hao et al, 2015) qui ont développé 3 modèles de régression caractérisés par une transformation logarithmique sur des données de panel pour prédire la consommation de charbon en 2020. Le présent ouvrage ne développe pas plus ces méthodes car plusieurs études bibliographiques à l'instar des travaux (Azhar et al, 2016) traitent de cette famille de méthode.

Enfin, il s'ensuit le développement des modèles de séries temporelles jugées plus adéquates car intégrant la notion d'historicité des données. On peut citer comme articles, l'étude de (Chujai et al, 2013) qui dresse une comparaison des modèles ARMA et ARIMA en matière de prévision de consommation d'électricité à court, moyen et long terme. Les modèles qui ont été estimés à l'aide de la méthodologie de Box-Jenkins ont permis de conclure que le modèle ARIMA est préférable en termes de prévisions mensuelles et semestrielles tandis que le modèle ARMA est le plus adapté au regard d'une périodicité journalière et hebdomadaire. Les critères d'évaluation retenus dans cette étude sont l'AIC et le RMSE.

Un an après, soit en 2014, (Yasmeen and Sharif, 2014) ont développé et comparé quatre modèles de séries temporelles à savoir ARIMA, SARIMA, ARCH et GARCH en termes de prévision de consommation d'électricité mensuelles. Ces modèles qui ont été entraînés à partir des données collectées en Palestine entre janvier 1990 et décembre 2011, ont été estimés et

évalués en utilisant 3 critères : AIC, BIC et le MAPE. Les deux premiers ont permis de mettre en évidence que les modèles les plus adéquates sont : ARIMA(3,1,2), SARIMA(2,1,2), ARCH(2) et GARCH(1,1). Tandis que le dernier à savoir le MAPE a été utilisé pour évaluer leur performances prédictives. Il en ressort que le modèle ARIMA est le plus précis en termes de prévision de consommation d'électricité puisque ce dernier a obtenu un MAPE de 5.99 contre 10.51, 11.712 et 9.99 qui correspondent respectivement aux modèles SARIMA, ARCH et GARCH.

Cette fois-ci également, les états de l'art de (Deb et al, 2017 ; Azhar et al, 2016) peuvent être consultés pour plus de détails.

2.2 Modèles d'apprentissage automatique

Les hypothèses de normalité, de non-stationnarité et la difficulté liée au caractère non linéaire des données sont autant de faiblesses de la part des modèles statistiques étudiés précédemment. (Azhar et al, 2016). Ces faiblesses ont poussé les chercheurs à s'orienter vers les méthodes d'apprentissage automatique jugées plus adéquates notamment pour leur capacité à résoudre des problèmes non linéaires (Ahmad et al, 2014 ; Amalou et al, 2022). Parmi elles, les plus connues sont les méthodes d'apprentissage en ensemble (EL) et les machines à vecteur de support (SVM).

S'agissant des méthodes ensemblistes, (Wang and Srinivasan, 2016), ont comparé, par exemple, les performances d'un arbre de régression (RT) à celle d'une forêt d'arbres décisionnelles (EBT) en matière de prévision de consommation d'électricité. Les modèles qui utilisent comme variables exogènes les données météorologiques et l'occupation du logement ont été entraînés sur 89% des observations et testés sur les 11% restantes. Les résultats suggèrent que la forêt d'arbres décisionnelles performe mieux que l'arbre de régression au regard du R^2 (0.90 contre 0.82), du MAPE (3.17% contre. 3.89%) et du RMSE (0.93 vs. 0.88).

Enfin, s'agissant du modèle de SVM, (Dong et al, 2005) dans leur célèbre étude ont démontré que le modèle de machine à vecteurs support (SVM) fait partie des modèles d'analyse de données les plus précis à cause notamment de leur capacité à atténuer les effets du surapprentissage et à comprendre les phénomènes à caractères non linéaire (Azhar et al, 2016). En effet, le modèle qui a été entraîné à partir des observations mensuelles provenant de 4 bâtiments commerciaux a obtenu un coefficient de variation (CV) inférieur à 3% et une erreur de pourcentage en dessous de 4%.

Face à cette efficacité des revues de littérature plus approfondis ont été effectuées (Ahmad et al, 2014 ; Deb et al, 2017).

2.3 Modèles d'apprentissage profond

Bien que l'efficacité de ces algorithmes d'apprentissage automatique soit indéniable, ces derniers nécessitent toutefois des optimisations intensives et un temps de calcul relativement long (Ahmad et al, 2014 ; Amalou et al, 2022). Par conséquent, c'est pour pallier ces insuffisances, que les modèles d'apprentissage profond à l'instar des Perceptrons Multicouches (MLP), des Réseaux de neurones Convolutifs (CNN) et Récurrents (RNN) sont proposés.

Ainsi, dans leur étude, (Azdeh et al, 2008) ont développé un MLP pour prédire la consommation annuelle d'électricité dans les secteurs à forte intensité énergétique. Le réseau de neurone, caractérisé par une fonction d'activation sigmoïde a obtenu un MAPE de 0.0099 qui est largement inférieur à celui d'un modèle de régression non linéaire évalué à 0.075.

Enfin, (Amalou et al, 2022) ont construit et comparé un modèle d'apprentissage profond et deux autres modèles hybrides. Il est question d'un réseau de neurone récurrent classique (RNN), d'un modèle de Long Short Term Memory (LSTM) et d'un modèle à Unité récurrente fermée (GRU). Les résultats indiquent que le GRU performe mieux que le LSTM et largement mieux que le RNN classique.

Bien que l'utilisation des réseaux de neurones pour la prévision de la consommation d'énergie soit un sujet de recherche largement documenté (Ahmad et al, 2014 ; Deb et al, 2017), il est important de noter que ces intelligences artificielles à l'instar des SVM souffrent d'un problème de « boîte noire » qui leur prive de toute forme explicabilité. (Foucquier et al, 2013).

2.4 Modèles hybrides

Il en va de soi que chacune des méthodes énumérées ci-dessus revêt des avantages comme des inconvénients. De ce fait, c'est dans but de tirer parti des forces uniquement de ces méthodes qu'une approche par hybridation, bien que plus complexes, est de plus en plus privilégiée.

Enfin, cette approche qui consiste à fusionner des modèles issues de différentes catégories dans le but dans de conserver uniquement leurs avantages est aujourd'hui considérée comme l'une plus efficace en matière de prévision et d'explicabilité.

Parmi ces modèles, on retrouve le modèles à machine à vecteurs de support des moindres carrés (LSSVM) qui offre un gain considérable de temps de calcul et une meilleure précision que les SVM. Il a notamment été utilisé dans l'étude de (Kaytez et al, 2015) où il est comparé à une régression multiple et un réseau de neurones récurrent. Les résultats indiquent que les prévisions du LSSVM sont plus précises que celles des deux modèles au regard du MAPE et du RMSE.

Enfin, comme dernier modèle hybride proposé, on retrouve les réseaux bayésiens dynamiques qui ont été récemment utilisés pour prédire la consommation d'électricité (Aulia et al, 2024) et la production d'énergie solaire (Zhang et al, 2024; Singh et al, 2018). Cependant, l'application de ces réseaux probabiliste est encore moins répandue bien que très prometteur.

En définitive, l'efficacité énergétique est un enjeu majeur qui cristallise à la fois l'opinion publique et la recherche scientifique. L'une des approches privilégiée pour atteindre cet objectif reste la prévision de la consommation d'énergie. Bien que cette dernière semble être un phénomène complexe à modéliser en raison notamment de son caractère multifactoriel et non linéaire, les méthodes d'analyse de données de plus en plus sophistiquées sont développées, réduisant ainsi, au fil du temps, les erreurs de prévision et le temps de calcul.

3 TABLEAU DE SYNTHÈSE

Auteurs	Données	Périodicité	Variable d'intérêt	Variables Explicatives	Méthodes	Résultats
Al-Garni et al, 1994	Arabie Saoudite (1987-1993)	Mois	Consommation d'électricité	Température, humidité, radiation solaire, population.	Régression Stepwise	L'hypothèse de normalité des résidus a été acceptée
Tunc et al, 2006	Turquie (1980-2001)	Année	Consommation d'électricité	Coûts de production, coûts fixes et coûts variables lié à la construction	Régression linéaire Multiple	Au regard des prévision, les centrales hydroélectriques et nucléaires sont importantes pour la soutenabilité de la consommation d'énergie.
Hao et al, 2015	Chine (1995-2012)	Année	Consommation de charbon par habitant	PIB par habitant, Taux d'urbanisation, Taux d'ouverture, valeur ajoutée de l'industrie secondaire	Régression avec une transformation logarithmique	Les prévisions faites par le modèle de régression indiquent une croissance de la consommation de charbon en chine jusqu'en 2020.

Chujai et al, 2013	France (2006-2010)	Heure, Semaine, Mois, Année	Consommation d'électricité	-	ARMA, ARIMA	Les Résultats indiquent que le modèle ARMA est plus adapté pour les prévisions à long terme d'une part. D'autre part, le modèle ARIMA est plus efficace pour les prévisions à court terme.
Yasmeen and Sharif, 2014	Palestine (1990-2011)	Mois	Consommation d'électricité	Univarié	ARIMA, GARCH, SARIMA	ARIMA (3,1,2) model is the most appropriate model for forecasting electricity consumption of Pakistan.
Wang and Srinivasan, 2016	Etats-Unis (2015.02.01-2015.02.28)	Heure	Consommation d'électricité	weather conditions, day types, and time of day	Ensemble Bagging Tree	Les capacités prédictives du modèle EBT sont supérieures à celles de l'arbre de régression (RT) avec une amélioration du MAPE de 18.5%.
Dong et al, 2005	Singapour (1996-2001)	Mois	Consommation d'électricité	Univarié	SVM	Comparé aux autres modèles, le SVM présente l'un des coefficients de variation les plus faibles. Il est inférieur à 3%.
Ahmad et al, 2014 (revue de littérature)	-	-	-	Univarié	-	Les méthodes d'apprentissage automatique ont comme principales limites : un besoin intensif d'optimisation et un temps de calcul relativement long

Azdeh et al, 2008	Iran (1997-2003)	Année	Consommation d'électricité	Le prix de l'électricité, Le nombre de consommateur par secteur, intensité énergétique, valeur ajoutée par secteur	Réseaux de neurones (Perceptron multi-couche)	Les résultats montrent que la moyenne des prévisions effectuées par le modèle de MLP est statistiquement identique à celle issues des données réelles avec un intervalle de confiance à 99%.
Amalou et al, 2022	Australie (2010-2014)	Heure	Consommation d'électricité	Univarié	Unité récurrente fermée	Le GRU a obtenu un meilleur RMSE que les modèles LSTM et RNN, 0.034 contre 0.039 et 0.051 respectivement.
Kaytez et al, 2015	Turquie (1970-2009)	Année	Consommation net d'électricité	La capacité énergétique, la production brute d'électricité, La population, Le total des abonnements	LS-SVM	Le modèle LSSVM a obtenu des meilleurs résultats que les modèles MLR et ANN de 1,70 % et 0,88 % respectivement.
Aulia et al, 2024 (revue de littérature)	-	-	-		-	Les réseaux bayésiens dynamiques surpassent les modèles d'apprentissage automatique et profond en termes d'
Zhang et al, 2024	Chine (2020-2021)	Minute	Production d'énergie solaire	weather information, operation indicators, sensor data, and output AC power	Réseau Bayésien Dynamique	Le réseau bayésien présente une meilleure gestion de l'incertitude.

Singh et al,2018	Royaume-Unis (2012-2015) Canada (2012-2014)	Minute	Consommation d'électricité	hour of the day, period of the day, weekday, week, month and season of the year as well as appliance-appliance associations	Réseau Bayésien Dynamique	Le modèle de RBD présente des Résultats supérieurs à ceux du SVM et du MLP.
------------------	--	--------	----------------------------	---	---------------------------	---

4 Etude empirique

4.1 Données

La base de données sélectionnée dans le cadre de cet ouvrage est une base de données publique (open-source) issue du programme de recherche (Smart Grid Smart City) dirigé conjointement par Ausgrid, un opérateur de distribution d'énergie et le ministère de l'énergie en Australie.

Ce programme développé en 2010 vise principalement à d'améliorer les politiques publiques en matière d'efficacité énergétique et à inciter la population à une gestion plus responsable des énergies disponibles. C'est dans cette optique que des capteurs intelligents appelés « smart meters » ont été déployés chez 78720 foyers afin de collecter des données relatives à la consommation d'énergie.

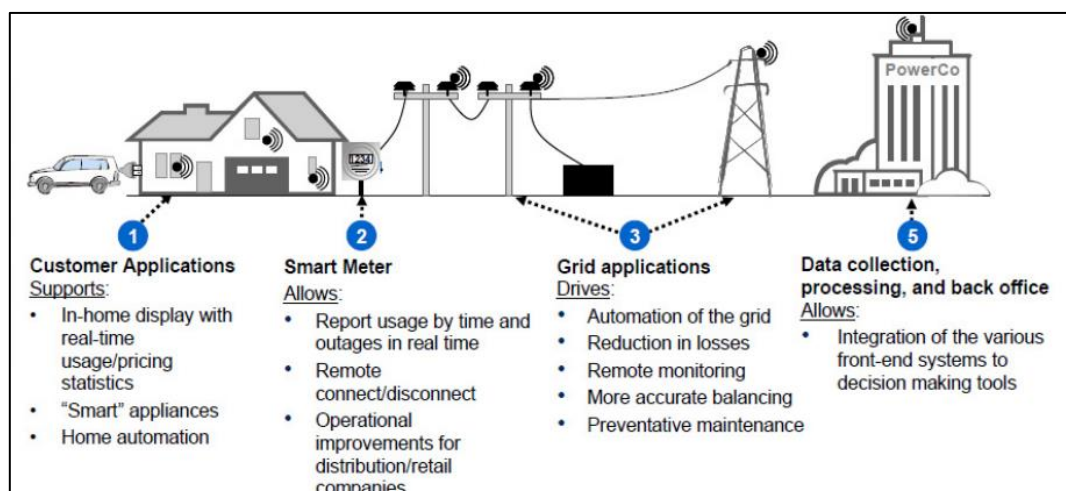
Figure 1.1: Traditional accumulation meter and a smart meter



Source: [Picture left] NSW Smart Meter Taskforce: *Discussion Paper*; [picture right] Ausgrid website, 12 September 2013.

Par la suite, ces données sont collectées, traitées et utilisées pour développer des application de gestion d'énergie en temps réel et alimenter la base de données publique connue sous le nom de Smart Grid Smart City (SGSC Database).

Cette base de données contient des données à haute fréquence (données de panel) en matière de consommation d'énergie de 78720 ménages collectées entre 2011 et 2014 pour un total de 1,048,575 observations. On y retrouve notamment des variables relatives à la consommation d'électricité, au type d'appareil électroménager, au type de logement, à la zone climatique etc.




4.2 Statistique descriptives

Avant toute chose, une analyse exploratoire qui comprend le calcul des paramètres de tendances centrales, des dispersions, des représentations graphiques (histogrammes, séries chronologiques) a été effectuée afin de comprendre la structure du jeu de données et de résumer les informations de celui-ci.


CRITERES	MONTHLY_ELEC_CONSUMP
count	1.048575e+06
mean	2.362661e-01
std	3.865180e-01
min	0.000000e+00
25%	4.200000e-02
50%	9.400000e-02
75%	2.300000e-01
max	10.01+00

En moyenne, la consommation mensuelle d'électricité entre 2011 et 2014 s'élève à 2.360 KWh. Cette consommation varie extrêmement puisqu'on obtient un coefficient de variable ($CV = \frac{\bar{x}}{\sigma}$) de 61%.

Un Box plot a été effectué afin d'étudier plus en détails le phénomène de consommation mensuelle d'électricité. Il en ressort que la consommation d'électricité mensuelle a augmenté en moyenne de façon structurellement entre 2011 et 2014. Tout comme sa dispersion. Par ailleurs, on peut noter des périodes à forte intensité comme



Suite à cette analyse descriptive brute dans laquelle les tendances en matière de consommation d'électricité mensuelles ont été analysées, une étape de traitement de nettoyage de la base de données a été effectuée. Suite à cette étape, seuls 40 individus qui contiennent des informations observés au moins pendant 30 jours ont été sélectionnés.



A la suite de cela, un graphique a été suggéré pour représenter l'évolution mensuelle de la consommation d'électricité par individu. Comme on peut le constater, la durée d'observation de ces individus varie énormément. Cela peut s'expliquer par l'adhésion au programme SGSC. En effet, certains individus ont le choix de quitter du programme SGSC tandis d'autres ont tout simplement disparu. Ainsi, cela donne lieu à des données manquantes plus précisément de type censure.

Toutes ces analyses ont servi à mettre en évidence la complexité du déploiement d'un modèle de prévision de la consommation d'énergie. Les données à haute fréquence, les données manquantes et les limites des algorithmiques sont autant de problématiques rencontrées dans le cadre de cette étude et qui devront être résolues pour garantir la fiabilité des résultats.

5 BIBLIOGRAPHIQUE

- **Papon, P. (2024).** AIE (Agence internationale de l'énergie). World Energy Outlook 2023, Paris: AIE octobre 2023, 353 p. URL: <https://iea.blob.core.windows.net/assets/42b23c45-78bc-4482-b0f9-eb826ae2da3d/WorldEnergyOutlook2023.pdf>. Consulté le 10 janvier 2024. *Futuribles*, (2), 114-117.
- **Ritchie, H., Roser, M., & Rosado, P. (2024).** *Energy Production and Consumption (Our World in Data, 2024)*.

- **Amasyali, K., & El-Gohary, N. M. (2018).** A review of data-driven building energy consumption prediction studies. *Renewable and Sustainable Energy Reviews*, 81, 1192-1205.
- **Al-Garni, A. Z., Zubair, S. M., & Nizami, J. S. (1994).** A regression model for electric-energy-consumption forecasting in Eastern Saudi Arabia. *Energy*, 19(10), 1043-1049.
- **Tunç, M., Çamdali, Ü., & Parmaksizoğlu, C. (2006).** Comparison of Turkey's electrical energy consumption and production with some European countries and optimization of future electrical power supply investments in Turkey. *Energy Policy*, 34(1), 50-59.
- **Hao, Y., Zhang, Z. Y., Liao, H., & Wei, Y. M. (2015).** China's farewell to coal: A forecast of coal consumption through 2020. *Energy Policy*, 86, 444-455.
- **Chujai, P., Kerdprasop, N., & Kerdprasop, K. (2013, March).** Time series analysis of household electric consumption with ARIMA and ARMA models. In *Proceedings of the international multiconference of engineers and computer scientists* (Vol. 1, pp. 295-300).
- **Yasmeen, F., & Sharif, M. (2014).** Forecasting electricity consumption for Pakistan. *International Journal of Emerging Technology and Advanced Engineering*, 4(4), 496-503.
- **Wang, Z., Srinivasan, R., & Wang, Y. (2016).** Homogeneous ensemble model for building energy prediction: a case study using ensemble regression tree. *Proceedings of the 2016 ACEEE Summer Study on Energy Efficiency in Buildings, Pacific Grove, CA, USA*, 21-26.
- **Dong, B., Cao, C., & Lee, S. E. (2005).** Applying support vector machines to predict building energy consumption in tropical regions. *Energy and Buildings*, 37(5), 545-553.
- **Ahmad, A. S., Hassan, M. Y., Abdullah, M. P., Rahman, H. A., Hussin, F., Abdullah, H., & Saidur, R. (2014).** A review on applications of ANN and SVM for building electrical energy consumption forecasting. *Renewable and Sustainable Energy Reviews*, 33, 102-109.
- **Azadeh, A. G. H. A. D. E. R. I., Ghaderi, S. F., & Sohrabkhani, S. (2008).** Annual electricity consumption forecasting by neural network in high energy consuming industrial sectors. *Energy Conversion and management*, 49(8), 2272-2278.
- **Amalou, I., Mouhni, N., & Abdali, A. (2022).** Multivariate time series prediction by RNN architectures for energy consumption forecasting. *Energy Reports*, 8, 1084-1091.
- **Kaytez, F., Taplamacioglu, M. C., Cam, E., & Hardalac, F. (2015).** Forecasting electricity consumption: A comparison of regression analysis, neural networks and least squares support vector machines. *International Journal of Electrical Power & Energy Systems*, 67, 431-438.
- **Aulia, H., Syaharuddin, S., Mandailina, V., Gervas, H. E., & Ashraf, H. (2024).** Probabilistic Forecasting of Energy Consumption using Bayesian Dynamic Linear Models. *Aceh International Journal of Science and Technology*, 13(1), 68-78.
- **Zhang, Q., Yan, H., & Liu, Y. (2024).** Power generation forecasting for solar plants based on Dynamic Bayesian networks by fusing multi-source information. *Renewable and Sustainable Energy Reviews*, 202, 114691.
- **Singh, S., & Yassine, A. (2018).** Big data mining of energy time series for behavioral analytics and energy consumption forecasting. *Energies*, 11(2), 452.

